

TEA018 - Hidrologia Ambiental

Hidrologia Estatística

Exemplos

Emílio Graciliano Ferreira Mercuri

Departamento de Engenharia Ambiental

Universidade Federal do Paraná (UFPR)

Statistics is a science of description, not causality.

Outline

Agenda de atividades

- Funções de probabilidade e de frequência
- Parâmetros estatísticos
- Ajustando distribuições de probabilidades aos dados
- Distribuições de probabilidade para dados hidrológicos
 - Distribuições Normal, exponencial


Exemplo - Cálculo da probabilidade da precipitação anual > ou < do que um certo valor

Os valores da precipitação anual em College Station, Texas, de 1911 a 1979 são mostrados na Tabela e plotados como uma série temporal na Figura. Qual é a probabilidade da precipitação anual R em qualquer ano seja inferior a 35 polegadas? Maior que 45 pol? Entre 35 e 45 polegadas?

TABLE 11.1.1
Annual Precipitation in College Station, Texas, 1911–1979 (in)

Year	1910	1920	1930	1940	1950	1960	1970
0		48.7	44.8	49.3	31.2	46.0	33.9
1	39.9	44.1	34.0	44.2	27.0	44.3	31.7
2	31.0	42.8	45.6	41.7	37.0	37.8	31.5
3	42.3	48.4	37.3	30.8	46.8	29.6	59.6
4	42.1	34.2	43.7	53.6	26.9	35.1	50.5
5	41.1	32.4	41.8	34.5	25.4	49.7	38.6
6	28.7	46.4	41.1	50.3	23.0	36.6	43.4
7	16.8	38.9	31.2	43.8	56.5	32.5	28.7
8	34.1	37.3	35.2	21.6	43.4	61.7	32.0
9	56.4	50.6	35.1	47.1	41.3	47.4	51.8

Solução no Google Colab:
<https://drive.google.com/file/d/167nE9e00fYIFO7m-AgagYHMHm3HAVg3A/view?usp=sharing> ■




(a) Annual precipitation.

Funções de probabilidade e de frequência

- Se as observações em uma amostra forem distribuídas de forma idêntica (cada valor amostral extraído da mesma distribuição de probabilidade), elas poderão ser organizadas para formar um **histograma de frequência**.
- Primeiro, o intervalo viável da variável aleatória é dividido em intervalos discretos, depois o número de observações dentro de cada intervalo é contado e, finalmente, o resultado é plotado como um gráfico de barras, como mostrado na Figura para precipitação anual em College Station. ■

Histograma de frequência da Precipitação anual na College Station, Texas



Funções de probabilidade e de frequência

- Se o número de observações n_i no intervalo i cobrindo o intervalo $[x_i - \Delta x, x_i]$ for dividido pelo número total de observações n , o resultado é a

função frequência relativa $f_s(x)$:

$$f_s(x) = \frac{n_i}{n}$$

que é uma estimativa da probabilidade:


$$P(x_i - \Delta x \leq X \leq x_i)$$

- A soma dos valores das frequências relativas até um determinado ponto é a **função frequência**

cumulativa $F_s(x)$:

$$F_s(x_i) = \sum_{j=1}^i f_s(x_j) \blacksquare$$

Histograma de frequência da Precipitação anual na College Station, Texas



Funções de probabilidade e de frequência

- Se o número de observações n_i no intervalo i cobrindo o intervalo $[x_i - \Delta x, x_i]$ é dividido pelo número total de observações n , o resultado é a **função frequência relativa** $f_s(x)$:

$$f_s(x) = \frac{n_i}{n}$$

que é uma estimativa da probabilidade:

$$P(x_i - \Delta x \leq X \leq x_i)$$

- A soma dos valores das frequências relativas até um determinado ponto x_i é a **função frequência cumulativa** $F_s(x)$:

$$F_s(x_i) = \sum_{j=1}^i f_s(x_j)$$

- As *funções frequência relativa e frequência cumulativa* são definidas para uma **amostra**; funções correspondentes para a **população** são obtidas pelos limites abaixo.
- A **função densidade de probabilidade** $f(x)$ é:

$$f(x) = \lim_{\substack{n \rightarrow \infty \\ \Delta x \rightarrow 0}} \frac{f_s(x)}{\Delta x}$$

- A função frequência cumulativa torna-se a **função distribuição de probabilidade** $F(x)$:

$$F(x) = \lim_{\substack{n \rightarrow \infty \\ \Delta x \rightarrow 0}} F_s(x) \blacksquare$$

Funções de probabilidade e de frequência

- A **função densidade de probabilidade** $f(x)$ é a derivada da **função distribuição de probabilidade** $F(x)$:

$$f(x) = \frac{dF(x)}{dx}$$


- Para um determinado valor de x , $F(x)$ é a probabilidade cumulativa (ou acumulada) $P(X \leq x)$, e pode ser expressa como a integral da função de densidade de probabilidade no intervalo $X \leq x$:

$$P(X \leq x) = F(x) = \int_{-\infty}^x f(u) du$$

- O valor teórico da função frequência relativa, é chamada **função de probabilidade incremental**:

$$\begin{aligned} p(x_i) &= P(x_i - \Delta x \leq X \leq x_i) \\ &= \int_{x_i - \Delta x}^{x_i} f(x) dx \\ &= \int_{-\infty}^{x_i} f(x) dx - \int_{-\infty}^{x_i - \Delta x} f(x) dx \quad \blacksquare \\ &= F(x_i) - F(x_i - \Delta x) \\ &= F(x_i) - F(x_{i-1}) \end{aligned}$$

Funções de probabilidade e de frequência



Função densidade de probabilidade

- Uma das funções densidade de probabilidade mais conhecidas é a curva gaussiana (distribuição normal):

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right] \quad \text{onde } \mu \text{ e } \sigma \text{ são parâmetros (média e desvio padrão).}$$

O caso mais simples de uma distribuição normal é conhecido como **distribuição normal padrão** ou **distribuição normal unitária**.

Nesse caso especial adota-se $\mu = 0$ e $\sigma^2 = 1$.

Esta função pode ser simplificada definindo a **variável normal padrão** $z = \frac{x - \mu}{\sigma}$

A **distribuição normal padrão** tem função densidade de probabilidade: $f(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2} \quad -\infty \leq z \leq \infty$

E uma função distribuição de probabilidade. $F(z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du$

$F(z)$ não tem forma analítica. Os valores de $F(z)$ podem ser obtidos pelo polinômio:

$$B = \frac{1}{2} [1 + 0.196854 |z| + 0.115194 |z|^2 + 0.000344 |z|^3 + 0.019527 |z|^4]^{-4}$$

onde $|z|$ é o valor absoluto de z e a distribuição normal padrão é:

$$\begin{aligned} F(z) &= B \quad \text{para } z < 0 \\ &= 1 - B \quad \text{para } z \geq 0 \end{aligned}$$


Exemplo 2 - Atividade em Sala

Qual é a probabilidade de que a **variável aleatória normal padrão z** seja:

- a) Menor que -2?
- b) Menor que 1?
- c) Quanto vale $P(-2 < z < 1)$?

Solução no Google Colab:

<https://colab.research.google.com/drive/1UERdkxDltqnRbb-jgwX6fveAWPmvRrez?usp=sharing>



Parâmetros estatísticos

- Valor esperado

$$E(X) = \mu = \int_{-\infty}^{\infty} x f(x) dx$$

$E(X)$ é o **primeiro momento** da variável aleatória, uma medida do ponto médio ou “tendência central” da distribuição.

- A média amostral é:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Ponto Médio


Population parameter	Sample statistic
1. <i>Midpoint</i>	
Arithmetic mean	
$\mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Median	
x such that $F(x) = 0.5$	50th-percentile value of data
Geometric mean	
antilog $[E(\log x)]$	$\left(\prod_{i=1}^n x_i \right)^{1/n}$

1º momento

Variabilidade

Espalhamento dos dados

Variância, desvio padrão e coeficiente de variação



(a) Standard deviation σ .

Population parameter

Sample statistic

2. Variability

Variance

$$\sigma^2 = E[(x - \mu)^2]$$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Standard deviation

$$\sigma = \{E[(x - \mu)^2]\}^{1/2}$$

$$s = \left[\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^{1/2}$$

Coefficient of variation

$$CV = \frac{\sigma}{\mu}$$


$$CV = \frac{s}{\bar{x}}$$

2º momento

$$\sigma^2 = \text{Var}(X) = E[(X - \mu)^2] = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$$

Simetria

Coeficiente de assimetria



(b) Coefficient of skewness C_s .

Population parameter	Sample statistic
----------------------	------------------

3. Symmetry

Coefficient of skewness

$$\gamma = \frac{E[(x - \mu)^3]}{\sigma^3}$$


$$C_s = \frac{n \sum_{i=1}^n (x_i - \bar{x})^3}{(n-1)(n-2)s^3}$$

3º momento

$$\gamma = \frac{E[(x - \mu)^3]}{\sigma^3} = \frac{1}{\sigma^3} \int_{-\infty}^{+\infty} (x - \mu)^3 f(x) dx$$

Exemplo 3 - Atividade em sala

Calcule a **média amostral**, o **desvio padrão amostral** e o **coeficiente de assimetria amostral** dos dados para a precipitação anual em College Station, Texas, de 1970 a 1979. Os dados são fornecidos no exemplo 1.



Solução no Google Colab:

https://drive.google.com/file/d/18iRU8veDTSEdGFhbwt3-hlC_gDbTTB/view?usp=sharing

Ajustando uma distribuição de probabilidade aos dados

O livro apresenta dois métodos:

1. Método dos momentos (veremos esse)
2. Método da Máxima verossimilhança

Método dos momentos

- Desenvolvido por Karl Pearson em 1902.
- Ele considerou que boas estimativas dos parâmetros de uma distribuição de probabilidade são aquelas para as quais os momentos da função densidade de probabilidade em torno da origem são iguais aos momentos correspondentes dos dados amostrais. ■

Exemplo - Média da Distribuição Exponencial

- A distribuição exponencial pode ser usada para descrever vários tipos de dados hidrológicos, como os tempos entre chegadas de eventos de chuva (tempos entre o início das precipitações). Sua função densidade de probabilidade é $f(x) = \lambda e^{-\lambda x}$ para $x > 0$. Determine a relação entre o parâmetro λ e o primeiro momento em relação à origem, μ . ■

Exemplo - Média da Distribuição Exponencial

- A distribuição exponencial pode ser usada para descrever vários tipos de dados hidrológicos, como os tempos entre chegadas de eventos de chuva (tempos entre o início das precipitações). Sua função densidade de probabilidade é $f(x) = \lambda e^{-\lambda x}$ para $x > 0$. Determine a relação entre o parâmetro λ e o primeiro momento em relação à origem, μ . ■

Solução:

Da definição da média para população:

$$\mu = E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

$$= \int_0^{\infty} x \lambda e^{-\lambda x} dx$$

Integrando por partes, obtemos: $\mu = \frac{1}{\lambda}$

Dedução da Integral por partes em LaTeX!

Ou seja, podemos aproximar λ por: $\lambda = \frac{1}{\bar{x}}$ ■

Testando a qualidade do ajuste - Teste Estatístico de χ^2

A qualidade do ajuste de uma distribuição de probabilidade pode ser testada comparando valores teóricos e amostrais com o teste de χ^2 .

- O valor amostral da frequência relativa do intervalo i é $f_s(x_i) = n_i/n$
- O valor teórico da probabilidade para a população é $p(x_i) = F(x_i) - F(x_{i-1})$

O teste de χ^2 é dado por:

$$\chi_c^2 = \sum_{i=1}^m \frac{n[f_s(x_i) - p(x_i)]^2}{p(x_i)}$$

- onde m é o número de intervalos do histograma.
- Para descrever o teste de χ^2 precisamos da distribuição de probabilidade χ_ν^2 :
$$\chi_\nu^2 = \sum_{i=1}^{\nu} z_i^2$$
- Sendo ν o número de graus de liberdade $\nu = m - p - 1$, p é o número de parâmetros da distribuição a ser ajustada.
- Um **nível de confiança** deve ser escolhido para o teste e é frequentemente expresso como $1 - \alpha$, onde α é denominado **nível de significância**. Um valor típico para o **nível de confiança é 95%**.
- A **hipótese nula** para o teste é que a distribuição de probabilidade proposta se ajusta adequadamente aos dados. Esta hipótese é rejeitada (ou seja, o ajuste é considerado inadequado) se o valor de χ_c^2 for maior que o valor crítico $\chi_{\nu, 1-\alpha}^2$.

Exemplo 4 - Atividade em Sala

Utilizando o método dos momentos, ajuste a **distribuição normal** à **precipitação anual em College Station, Texas**, de 1911 a 1979.

Plote as funções frequência relativa e probabilidade incremental e as funções frequência cumulativa e probabilidade cumulativa. Use o teste de χ^2 para determinar se a **distribuição normal** se ajusta adequadamente aos dados.

Solução no Google Colab:

<https://drive.google.com/file/d/1Hy5E8a6YJREQOfgqqSVXQ8hIYFSqVJea/view?usp=sharing>