

TEA018 - Hidrologia Ambiental

Hidrologia Estatística e Distribuições para valores extremos

Análise Frequentista

Emílio Graciliano Ferreira Mercuri

Departamento de Engenharia Ambiental

Universidade Federal do Paraná (UFPR)

Statistics is a science of description, not causality.

Outline

Agenda de atividades




- Distribuições de Probabilidade para variáveis hidrológicas
- Séries de dados hidrológicos
 - Série completa, série de máximos anuais, série de valores extremos
- Distribuições para valores extremos
- Período de retorno para séries de valores extremos
- Análise de frequência usando **Fatores de Frequência**

Da última aula: **Período de Retorno T**

- O **período de retorno** (ou tempo de recorrência) é uma estimativa estatística que define o intervalo médio de anos em que um evento natural extremo (como chuvas intensas, secas ou inundações) é igualado ou superado.
- $T = 1/p$
- p é a probabilidade de ocorrência de um evento aleatório X maior do que x_T em qualquer observação, que é igual ao inverso do período de retorno.
- $P(X \geq x_T) = \frac{1}{T}$

Série completa, série de máximos anuais, série de valores extremos

- Dada uma série de precipitação, evapotranspiração ou vazão:



Distribuições de Probabilidade para variáveis hidrológicas

Veremos as **funções densidade de probabilidade** para as distribuições:

- Normal
- Lognormal
- Exponencial
- Gamma
- Pearson Tipo III
- Log Pearson Tipo III
- Valores Extremos Tipo I
- 

Distribuição Normal e Teorema do limite central

- A distribuição normal surge do **Teorema Central do Limite**, que estabelece que, se uma sequência de variáveis aleatórias X_i for independente e identicamente distribuída, com média μ e variância σ^2 , então a distribuição da soma de n dessas variáveis, $Y = \sum_{i=1}^n X_i$, tende para uma distribuição normal com média $n\mu$ e variância $n\sigma^2$ à medida que n se torna grande.
- O importante desse teorema é que esse resultado é válido independentemente da função de distribuição de probabilidade de X .
- Variáveis hidrológicas, como a precipitação anual, que podem ser interpretadas como a soma dos efeitos de muitos eventos independentes, tendem a seguir uma distribuição normal.
- As principais limitações da distribuição normal para descrever variáveis hidrológicas são:
 - A distribuição normal está definida em todo o intervalo contínuo $[-\infty, \infty]$, enquanto a maioria das variáveis hidrológicas assume apenas valores não negativos.
 - A distribuição normal é simétrica em torno da média, enquanto os dados hidrológicos frequentemente apresentam assimetria, geralmente com cauda mais longa para valores elevados.



Distribuição Lognormal

- Se a variável aleatória $Y = \log X$ possui distribuição normal, então diz-se que a variável X segue uma distribuição lognormal.
- Chow (1954) argumentou que essa distribuição é apropriada para variáveis hidrológicas formadas pelo produto de várias outras variáveis. De fato, se $X = X_1 X_2 X_3 \cdots X_n$, então
- Pelo Teorema Central do Limite, a soma $\sum_{i=1}^n Y_i$ tende a uma distribuição normal quando n é suficientemente grande, desde que as variáveis X_i sejam independentes e identicamente distribuídas.
- **Vantagens:**
 - é limitada inferiormente por zero $X > 0$, característica compatível com muitas variáveis hidrológicas;
 - a transformação logarítmica tende a reduzir a assimetria positiva frequentemente observada em dados hidrológicos; (o logaritmo comprime valores elevados proporcionalmente mais do que valores pequenos.)
- **Limitações:**
 - possui apenas dois parâmetros, o que pode restringir sua flexibilidade;
 - exige que os logaritmos dos dados apresentem simetria em torno de sua média, condição que nem sempre é observada em séries hidrológicas reais.



Distribuições de probabilidade para ajuste de dados hidrológicos

Distribution	Probability density function	Range	Equations for parameters in terms of the sample moments
Normal	$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$	$-\infty \leq x \leq \infty$	$\mu = \bar{x}, \sigma = s_x$
Lognormal	$f(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(y - \mu_y)^2}{2\sigma_y^2}\right)$ where $y = \log x$	$x > 0$	$\mu_y = \bar{y}, \sigma_y = s_y$
Exponential	$f(x) = \lambda e^{-\lambda x}$	$x \geq 0$	$\lambda = \frac{1}{\bar{x}}$
Gamma	$f(x) = \frac{\lambda^\beta x^{\beta-1} e^{-\lambda x}}{\Gamma(\beta)}$ where Γ = gamma function	$x \geq 0$	$\lambda = \frac{\bar{x}}{s_x^2}$ $\beta = \frac{\bar{x}^2}{s_x^2} = \frac{1}{CV^2}$

Distribuição Exponencial

- Algumas sequências de eventos hidrológicos, como a ocorrência de precipitação, podem ser consideradas **processos de Poisson**, nos quais os eventos ocorrem instantaneamente e de forma independente ao longo de um horizonte temporal ou espacial.
- O intervalo de tempo entre eventos sucessivos, denominado **tempo entre chegadas** (*interarrival time*), é descrito pela distribuição exponencial, cujo parâmetro λ é o inverso da média de ocorrência dos eventos.
- A distribuição exponencial é utilizada para descrever os tempos entre perturbações aleatórias em sistemas hidrológicos, como pulsos (*slugs*) de escoamento poluído que ingressam em cursos d'água quando a chuva remove poluentes da superfície do solo.
- **Vantagem:** facilidade de estimar o parâmetro λ a partir de dados observados.
- **Limitação:** a exigência de que cada evento ocorra de forma completamente independente dos eventos vizinhos. (Essa hipótese nem sempre é válida em processos hidrológicos. Por exemplo, a passagem de uma frente atmosférica pode gerar diversas pancadas de chuva correlacionadas entre si.)

Distribuição Gamma

- O tempo necessário para que um número β de eventos ocorra em um **processo de Poisson** é descrito pela distribuição gama.
- A **distribuição gama** corresponde à distribuição da soma de β variáveis aleatórias independentes e identicamente distribuídas, cada uma seguindo uma **distribuição exponencial**.
- Essa distribuição é particularmente útil para representar variáveis hidrológicas assimétricas, sem a necessidade de aplicar transformações logarítmicas aos dados.
- Um exemplo de aplicação é a modelagem da distribuição das alturas de precipitação em eventos de chuva.
- A distribuição gama envolve a função gama $\Gamma(\beta)$, definida para valores inteiros positivos de β por: $\Gamma(\beta) = (\beta - 1)!$
- De forma mais geral, para valores não inteiros de β , a função gama é definida pela integral: $\Gamma(\beta) = \int_0^{\infty} u^{\beta-1} e^{-u} du$
- Essa definição generaliza o conceito de fatorial para números reais e complexos positivos.
- A distribuição gama de dois parâmetros utiliza:
 - β — parâmetro de forma;
 - λ — parâmetro de taxa.
- Uma característica importante da distribuição gama é que seu limite inferior é igual a zero: $x \geq 0$

Distribuições de probabilidade para ajuste de dados hidrológicos

Distribution	Probability density function	Range	Equations for parameters in terms of the sample moments
Pearson Type III (three parameter gamma)	$f(x) = \frac{\lambda^\beta (x - \epsilon)^{\beta-1} e^{-\lambda(x-\epsilon)}}{\Gamma(\beta)}$	$x \geq \epsilon$	$\lambda = \frac{s_x}{\sqrt{\beta}}, \beta = \left(\frac{2}{C_s}\right)^2$ $\epsilon = \bar{x} - s_x \sqrt{\beta}$
Log Pearson Type III	$f(x) = \frac{\lambda^\beta (y - \epsilon)^{\beta-1} e^{-\lambda(y-\epsilon)}}{x \Gamma(\beta)}$ where $y = \log x$	$\log x \geq \epsilon$	$\lambda = \frac{s_y}{\sqrt{\beta}},$ $\beta = \left[\frac{2}{C_s(y)}\right]^2$ $\epsilon = \bar{y} - s_y \sqrt{\beta}$ (assuming $C_s(y)$ is positive)
Extreme Value Type I	$f(x) = \frac{1}{\alpha} \exp \left[-\frac{x-u}{\alpha} - \exp \left(-\frac{x-u}{\alpha} \right) \right]$	$-\infty < x < \infty$	$\alpha = \frac{\sqrt{6}s_x}{\pi}$ $u = \bar{x} - 0.5772\alpha$

Distribuição de Pearson Tipo III

- A distribuição de Pearson Tipo III, também conhecida como **distribuição gama de três parâmetros**, introduz um terceiro parâmetro, denominado limite inferior ϵ .
- Pelo método dos momentos, três momentos amostrais: média, desvio padrão e coeficiente de assimetria

podem ser transformados nos três parâmetros da distribuição: λ, β, ϵ .

- O sistema de distribuições de Pearson é composto por sete tipos distintos de distribuições. Todas essas distribuições são soluções da equação diferencial

$$\frac{d[f(x)]}{dx} = \frac{f(x)(x - d)}{C_0 + C_1x + C_2x^2}$$

- d é a *moda* da distribuição, (valor de x para o qual $f(x)$ atinge o máximo), C_0 , C_1 e C_2 são constantes.
- Quando $C_2 = 0$ a solução da equação diferencial corresponde à distribuição de Pearson Tipo III, cuja função densidade de probabilidade possui a forma característica da distribuição gama de três parâmetros.
- Quando $C_1 = C_2 = 0$ a solução da equação diferencial torna-se a distribuição normal.
- Portanto, a **distribuição normal** pode ser interpretada como um **caso particular** da distribuição de **Pearson Tipo III**, correspondente a uma variável sem assimetria.

Distribuição Log-Pearson Tipo III

- Se $\log X$ segue uma distribuição de Pearson Tipo III, então a variável aleatória X é dita seguir uma distribuição Log-Pearson Tipo III.
- A distribuição Log-Pearson Tipo III combina duas características importantes:
 1. a transformação logarítmica dos dados;
 2. a flexibilidade da distribuição de Pearson Tipo III para representar diferentes níveis de assimetria.
- Como caso particular, quando $\log X$ é simétrico em torno de sua média, o coeficiente de assimetria é nulo e a distribuição **Log-Pearson Tipo III** reduz-se à **distribuição lognormal**.
- Dessa forma, a distribuição lognormal pode ser interpretada como um caso especial da distribuição Log-Pearson Tipo III.
- A posição do parâmetro limite inferior ϵ depende da assimetria dos dados observados.
 - Para dados com assimetria positiva, $\log X \geq \epsilon$ de modo que ϵ representa um limite inferior para os valores transformados.
 - Se os dados de assimetria negativa $\log X \leq \epsilon$ e ϵ é um limite superior.
- Quanto maior a assimetria positiva, maior a importância do parâmetro ϵ para representar adequadamente a cauda da distribuição;
- a presença desse terceiro parâmetro torna a distribuição mais flexível que a distribuição lognormal;
- essa flexibilidade permite um melhor ajuste a séries hidrológicas de eventos extremos, que frequentemente apresentam caudas longas e forte assimetria.
- Por essa razão, a distribuição Log-Pearson Tipo III tornou-se uma das distribuições mais utilizadas em estudos de frequência de cheias e dimensionamento hidráulico.

Distribuições de Valores Extremos

- Valores extremos correspondem a valores máximos ou mínimos selecionados de um conjunto de observações.
- Um exemplo clássico em Hidrologia é a vazão máxima anual em uma determinada seção de rio, definida como a maior vazão observada em cada ano.
- A série formada pelos máximos anuais constitui uma amostra de valores extremos que pode ser analisada estatisticamente para estimar eventos raros e períodos de retorno.
- Fisher and Tippett (1928) demonstraram que as distribuições dos valores extremos selecionados a partir de amostras de qualquer distribuição de probabilidade convergem, quando o tamanho da amostra é grande, para uma das três formas limite de distribuições de valores extremos:
 - Tipo I (EVI)
 - Tipo II (EVII)
 - Tipo III (EVIII)
- As propriedades dessas distribuições foram posteriormente desenvolvidas por:
 - Gumbel (1941) para a **distribuição de Valor Extremo Tipo I (EVI)**;
 - Frechet (1927) para a distribuição de Valor Extremo Tipo II (EVII);
 - Weibull (1939) para a distribuição de Valor Extremo Tipo III (EVIII).

Distribuição de Valor Extremo Tipo I (EVI ou Gumbel)

- A função de distribuição acumulada da distribuição de Valor Extremo Tipo I (EVI) é

$$F(x) = \exp \left[-\exp \left(-\frac{x - u}{\alpha} \right) \right], \quad -\infty < x < \infty,$$

Sendo que u é a moda e α é um parâmetro de escala

Os parâmetros podem ser estimados a partir da média amostral $\bar{x}$ e do desvio padrão amostral s :

$$\alpha = \frac{\sqrt{6} s}{\pi}, \quad u = \bar{x} - 0.5772 \alpha$$

- Define-se a variável reduzida $y = \frac{x - u}{\alpha}$
- Substituindo essa definição na função de distribuição acumulada obtém-se

$$F(x) = \exp[-\exp(-y)]$$

- Isolando a variável reduzida: $y = -\ln \left[\ln \left(\frac{1}{F(x)} \right) \right]$

Distribuição de Valor Extremo Tipo I (EVI ou Gumbel)

- O período de retorno T está relacionado à probabilidade de excedência de um evento extremo.

Para um valor crítico x_T :

$$\frac{1}{T} = P(x \geq x_T)$$

- Como $F(x_T) = P(x < x_T)$, segue que

$$\frac{1}{T} = 1 - P(x < x_T)$$

- Portanto,

$$\frac{1}{T} = 1 - F(x_T) \quad \text{ou, de forma equivalente:} \quad F(x_T) = \frac{T-1}{T}$$

Substituindo na expressão da variável reduzida: $y = -\ln \left[\ln \left(\frac{1}{F(x)} \right) \right]$, obtém-se:

$$y_T = -\ln \left[-\ln \left(1 - \frac{1}{T} \right) \right]$$

- O valor hidrológico associado ao período de retorno T é então obtido da definição da variável reduzida:

$$x_T = u + \alpha y_T \quad \blacksquare$$

Exemplo: Os valores máximos anuais de precipitação com duração de 10 minutos em Chicago, Illinois, de 1913 a 1947, são apresentados na Tabela abaixo. Desenvolva um modelo para análise de frequência de precipitação em tempestades usando a distribuição de Valores Extremos Tipo I e calcule os valores máximos de precipitação com duração de 10 minutos em Chicago para períodos de retorno de 5, 10 e 50 anos.

**Annual maximum 10-minute rainfall
in inches at Chicago, Illinois, 1913–
1947**

Year	1910	1920	1930	1940
0		0.53	0.33	0.34
1		0.76	0.96	0.70
2		0.57	0.94	0.57
3	0.49	0.80	0.80	0.92
4	0.66	0.66	0.62	0.66
5	0.36	0.68	0.71	0.65
6	0.58	0.68	1.11	0.63
7	0.41	0.61	0.64	0.60
8	0.47	0.88	0.52	
9	0.74	0.49	0.64	

Mean = 0.649 in
Standard deviation = 0.177 in

Exemplo: Solução

Da Tabela: $\bar{x} = 0,649$ in e $s = 0,177$ in. As constantes do modelo são:

$$\alpha = \frac{\sqrt{6}s}{\pi} = \frac{\sqrt{6} \times 0.177}{\pi} = 0,138$$

$$u = \bar{x} - 0.5772\alpha = 0.649 - 0.5772 \times 0.138 = 0.569$$

- O modelo de Probabilidade é:

$$F(x) = \exp \left[-\exp \left(-\frac{x - 0.569}{0.138} \right) \right]$$

- Para determinar os valores de x_T para vários valores do período de retorno T , é conveniente usar a variável reduzida y_T . Para $T = 5$ anos:

$$y_T = -\ln \left[\ln \left(\frac{T}{T-1} \right) \right] = -\ln \left[\ln \left(\frac{5}{5-1} \right) \right] = 1.500$$

Retornando para a variável x_T

$$\begin{aligned} x_T &= u + \alpha y_T \\ &= 0.569 + 0.138 \times 1.500 \\ &= 0.78 \text{in} \end{aligned}$$

- Assim, a magnitude da precipitação em uma tempestade de 10 minutos com período de retorno de 5 anos em Chicago é de 0,78 polegadas. Pelo mesmo método, os valores para períodos de retorno de 10 e 50 anos podem ser demonstrados como sendo 0,88 polegadas e 1,11 polegadas, respectivamente. ■

Exercício: Considere os valores máximos anuais de precipitação com duração de 24h na bacia hidrográfica de cada grupo nos 30 anos da base CaBra.

Desenvolva um modelo para análise de frequência de precipitação em tempestades usando a distribuição de Valores Extremos Tipo I e calcule os valores máximos de precipitação com duração de 24 horas para períodos de retorno de 5, 10 e 50 anos.